

Recap Studio — Engine & Logic (Coder Handoff)

Local Mac tool. Source video → Burmese voiceover video + SRT. ဒီစာတမ်းက **engine** နဲ့ **logic** (transcript timing, translation, voice/video speed, video timing, SRT timing) ကို coder ဆီ လွှဲပို့ ရေးထားတာပါ။ UI မဟုတ်ဘဲ core logic ကိုပဲ အာရုံစိုက်ထားပါတယ်။

၁။ Engine က အလုပ်လဲ + Mode ၃ ခု

Input = video တစ်ခု (English/Chinese recap portrait)။ Output = Burmese voiceover တင်ထားတဲ့ mp4 + **.srt** ။ Processing mode ၃ ခု ရှိပြီး translation/voice/timing logic က mode အလိုက် ကွာပါတယ် -

Mode	Logic
Subtitle Only	Transcribe → translate → Burmese caption burn/attach။ Original audio ကျန်၊ voice မထည့်။
AI Recap	Transcript တစ်ခုလုံး → paragraph တစ်ခု Burmese narration → voice တစ်ဆက်တည်း → video ကို voice အရှည်နဲ့ ကိုက်အောင် ချဲ့/ဆန့်။
Dubbing	Scene-anchored blocks → smooth Burmese sentence per block → voice ကို scene အချိန်နဲ့ တွဲ → adaptive speed fit။ Dialogue scene = dialogue အဖြစ်။

၂။ Stack / Environment

Item	Value
Language	Python 3.12 (venv), FastAPI (server.py), local localhost:8000
Media	ffmpeg / ffprobe
Transcription	AssemblyAI (language auto-detect + word timings + speaker diarization)
Translation	Gemini (gemini-3.6-flash) – paid key
Voice (TTS)	edge-tts – my-MM-ThihaNeural (default), my-MM-NilarNeural
Core files	app.py (pipeline/engine), server.py (API), index.html (UI)

၃။ Pipeline အဆင့်များ

1. **Probe** – **ffprobe** နဲ့ duration + resolution။

2. **Extract audio** – `ffmpeg` → 16kHz mono MP3 (upload သေးအောင်)။
3. **Transcribe** — AssemblyAI `language_detection=True` + diarization → word timings + speaker labels။
4. **Translate** — mode အလိုက် (အောက်တွင်)။
5. **Voice** — edge-tts၊ WordBoundary timings ဖမ်း၊ chunk → silence-trim → concat (70ms fade)။
6. **Timing/fit** — mode အလိုက် sync + speed (အောက်တွင်)။
7. **Render** — crop → blur → caption → flip → mux။
8. **SRT** — final voice ရဲ့ word timing ကနေ short chunk (အောက်တွင်)။

၄။ Transcription Logic

- AssemblyAI ကိုပဲ သုံး (Whisper မသုံး)။ **language ကို အတင်း မသတ်မှတ်ရ** – `language_detection=True` ။ (source က Chinese/Douyin ဖြစ်တတ်လို့ en force ရင် hallucinate ဖြစ်တယ်။)
- Return: word-level timing + speaker label (diarization)။ ဒါတွေက dubbing block-grouping ရော SRT timing ရော အတွက် အခြေခံပါ။

၅။ Translation Logic (mode အလိုက်)

AI Recap

Transcript တစ်ခုလုံးကို Gemini နဲ့ **paragraph တစ်ခုတည်း** Burmese narration အဖြစ် ပြန် – rules:

- Original transcript ကို ပြန်မပြ/မထုတ်၊ summarize မလုပ်၊ အရေးကြီးအချက် မဖြတ်၊ scene/character အသစ် မထည့်။ Story order + meaning ကို ထိန်း။
- Simple spoken Burmese၊ မရှည်လွန်း၊ formal/ခက်တဲ့ စကားလုံး ရှောင်။ နာမည်/နေရာ = readable Burmese pronunciation။
- **ဂဏန်းအားလုံး Burmese စာလုံးနဲ့** – English digit (0-9) ရော Myanmar digit (၀-၉) ရော မသုံးရ (e.g. 1000 → တစ်ထောင်၊ 18 → ဆယ့်ရှစ်)။
- Paragraph တစ်ခုတည်း – line break/bullet/title မထည့်။ အဆုံးမှာ CTA: အဆက်ကြည့်ချင်ရင် Follow လုပ်ထားပါ။

Dubbing

- Scene block တစ်ခုချင်းကို **smooth complete Burmese sentence** အဖြစ် ပြန် – word-by-word fragment မဟုတ်၊ paragraph ရှည်ကြီးလည်း မဟုတ်။
- Dialogue scene (speaker ၂ ယောက် အလှည့်ကျ) = first-person, in-scene dialogue အဖြစ်။ Diarization speaker label သုံးပြီး turn ခွဲ။
- ကြားထဲက inter-word silence ကို ဖြည့် (mimic မလုပ်) – voice ချောစေဖို့။

Gemini gotcha ၂ ခု: (1) Gemini 3.x က `candidates[0].content.parts` ထဲ **thinking part** ရှေ့ဆုံး ပြန်ပေးတယ် - `thought` မဟုတ်တဲ့ part တွေကိုပဲ ပေါင်း (parts[0] ဖတ်ရင် ဗလာ)။ (2) prompt ထဲ literal `%` က `PROMPT % payload` ကို ဖျက်တယ် - placeholder + `.replace()` သုံး။

၆ | Voice + Speed Logic

- edge-tts default voice my-MM-ThihaNeural။ Base voice speed = +30% (pitch preserve)၊ user slider နဲ့ ထိန်းလို့ရ။
- **WordBoundary timings** ဖမ်းရ — edge-tts ရဲ့ WordBoundary event က စကားလုံးတိုင်းရဲ့ start time ပေးတယ်။ ဒါက SRT timing အတွက် အရေးအကြီးဆုံး (အောက် ၆၉)။
- ရှည်တဲ့ text ကို chunk ခွဲ → chunk တစ်ခုချင်း synth → leading/trailing silence trim → back-to-back concat (70ms fade join)။ ဗလာ/ပုဒ်ဖြတ်တာ line drop။

၇။ Timing & Sync Logic (CORE)

Dubbing — scene-anchored

Functions: `layout_track()` , `fit_global_timing()` , `build_voice_track()` , `verify_no_overlap()` .

- **layout_track()** — block တစ်ခုချင်း start = `max(block's scene start, previous block's end)` ။ Block တစ်ခု စောပြီးဆုံးရင် နောက် scene မရောက်မချင်း **HOLD (silence)** - ရှေ့ကို မဆွဲ။ (ဒါက voice ရှေ့ကျ/drift ဖြစ်တာ ကာကွယ်တယ်။) No overlap ever။
- **fit_global_timing()** — voice မီဒီယံထက် ရှည်ရင်: voice tempo ကို +30% → +45% အထိ တင် → မဆွဲသေးရင် video ကို **0.9x → 1.1x** range ထဲ ချိန် → နောက်ဆုံး freeze-extend။ (Thet allow: video 0.9-1.1x, voice +30-45% — dead silence ဖျောက်ဖို့။)
- **build_voice_track()** — trimmed clip တစ်ခုချင်းကို absolute time မှာ ချ + 70ms fade-in/out join။ (အရင် crossfade က boundary တိုင်း စကား ~20ms စားပြီး choppy ဖြစ်စေခဲ့ - ဒါ ပြင်ပြီး။)
- **verify_no_overlap()** — run တိုင်း assert။

AI Recap — video follows voice

- Paragraph တစ်ခုလုံးကို voice တစ်ဆက်တည်း synth (voice speed = user control)။
- Total voice duration တိုင်း → **video speed ကို video duration == voice duration ကွက်တိ ဖြစ်အောင် set**။ (voice 4:00 → video 4:00)။ Dead silence မရှိ။

၈။ Video Timing / Speed တွက်ပုံ

- **Dubbing:** global fit — voice_len vs video_len ချိန်ပြီး voice tempo (+30-45%) + video speed (0.9-1.1x) ကို bound ထဲ ရွေး။ Scene anchoring ထိန်း။

- **AI Recap:** `video_speed = original_video_len / voice_len` (video ကို voice နဲ့ ကိုက်အောင်)။
- Output မှာ `voice_duration == ffprobe_duration` ကွက်တိ (0.0s diff) ဖြစ်ရ - crossfade inflation ကို correct လုပ်ပြီးမှ တွက်။

၉။ SRT Timing Logic (အရေးကြီး)

- SRT ကို **final voice** ရဲ့ **real WordBoundary timestamps** ကနေ တွက်ရ - proportional estimate မလုပ်ရ။ Voice speed (+30% စသဖြင့်) apply ပြီးမှ boundary time ကို အဲဒီ factor နဲ့ scale။
- Short phrase chunk (~**3-6 word**, breath group တစ်ခု) - entry တစ်ခုမှာ တစ်ကြောင်း။ Break at space / ၊ / ။ / particle နောက် - word အလယ် မဖြတ်။
- Chunk start = first word ရဲ့ real time; end = နောက် chunk ရဲ့ start။ တကယ် mux ဖြစ်တဲ့ audio နဲ့ ဘဲဘဲ ကိုက်ရ (energy check ~0.2s tolerance)။
- MP3 chunk duration ကို frame header အစစ်ကနေ ဖတ် - word-boundary end ကနေ estimate မလုပ် (drift ဖြစ်တယ်)။

SRT ↔ TTS dependency: SRT sync က **edge-tts** ရဲ့ **WordBoundary** ပေါ်လုံးဝ မူတည်တယ်။ TTS provider ပြောင်းရင် (Gemini/Google TTS — word timing မပေးဘူး) SRT ကို generated audio ပြန် transcribe လုပ်ပြီး word time ယူရမယ် (ဒါမှမဟုတ် forced alignment)။

၁၀။ Render Pipeline Order (overlay အတွက် အရေးကြီး)

Video step order — **crop** → **blur** → **caption** → **flip** → **mux**။ Crop/aspect ကို အရင်ဆုံး လုပ်ရ (blur/caption box position က reframed frame ပေါ်မှန်ကန်ဖို့)။ Blur = seamless feathered gaussian (visible rectangle edge/sheen မရှိ)၊ box ဆွဲတဲ့ coordinate ↔ output coordinate letterbox-compensate လုပ်ရ။

၁၁။ Known Constraints / Gotchas

- SRT sync = edge-tts WordBoundary dependency (၆၉)။
- Gemini: thinking-part + % bug (၆၅)၊ 403/429/503 - paid key + backoff (5/20/45/70s across keys)၊ credit ကုန်တတ် (RESOURCE_EXHAUSTED)။
- AssemblyAI language auto-detect — en force မလုပ်ရ။
- edge-tts Burmese voice ၂ ခုသာ - voice variety လိုရင် Google Cloud TTS / Gemini TTS (my supported) သို့ ပြောင်း (ဒါပေမဲ့ word-timing မပါ → SRT re-transcribe)။
- TikTok URL download (yt-dlp) = upstream extractor အကြောင်း ခဏခဏ ကွဲ - reliable path = manual download + upload၊ ဒါမှမဟုတ် maintained download API (tikwm)။

၁၂။ Rebuild-Better အကြံ (coder အတွက်)

- **Module ခွဲ:** probe / audio / transcribe / segment / translate / tts / timing / render / subtitle + orchestrator။
- **Config ထုတ်:** voice speed range, chunk length, char budget, fit bounds, backoff — magic number တွေ တစ်နေရာ။
- **Scene detection:** speaker turn တင် မဟုတ်ဘဲ visual scene-cut (PySceneDetect/ffmpeg) ပေါင်း → sync ပိုကောင်း။
- **Forced alignment:** Burmese generated audio ပေါ် forced-align → SRT timing တင်းအောင် (TTS provider မရွေး)။
- **Cache:** transcript/translation/per-chunk mp3 ကို input hash နဲ့ key — re-run မြန်။
- **Cost/rate meter** + structured logging။